

Fundação Escola de Comércio Álvares Penteado

Ciência da Computação 4º Semestre

Psicologia, Liderança e Soft Skills

Arthur Paltrinieri Silva – 24026559

Lucas Kenichi Soares – 24026179

Pedro Della Rosa Antônio – 24026018

Pedro Dimitry Zyrianoff – 24026165

São Paulo – 2025

Sumário

1. Objetivo
2. Visão Geral da Solução
3. Tecnologias Utilizadas
4. Pipeline de Visão Computacional
 - 4.1 Captura de Imagem/Vídeo
 - 4.2 Detecção de Objetos (ROI)
 - 4.3 Classificação
 - 4.4 Contagem de Itens (Evitar Duplicidade)
5. Dataset
 - 5.1 Coleta de Dados
 - 5.2 Rotulagem
6. Treinamento do Modelo
 - 6.1 Métricas Utilizadas
7. Avaliação do Modelo
 - 7.1 Resultados Preliminares
 - 7.2 Matriz de Confusão
 - 7.3 Análise de Erros
8. Integração com Backend
9. Resultados da PoC
10. Limitações
11. Próximos Passos
12. Conclusão

1. Objetivo

O objetivo desta Prova de Conceito (PoC) é validar tecnicamente o núcleo de uma solução baseada em Visão Computacional e Inteligência Artificial capaz de:

- Detectar automaticamente produtos em uma esteira/rampa
- Classificar os itens (Arroz, Feijão, Macarrão)
- Registrar a confiança da predição
- Realizar contagem evitando duplicidade
- Persistir os dados com timestamp e identificação de equipe

Esta etapa não contempla acabamento final ou deploy completo, mas comprova a viabilidade técnica da solução.

2. Visão Geral da Solução

Segue captura de tela para exemplo de contagem:



A solução proposta consiste em um pipeline de IA composto pelas seguintes etapas:

1. Captura de imagem/vídeo
2. Detecção de objetos (ROI)
3. Classificação dos itens
4. Contagem com controle de duplicidade
5. Registro dos dados em backend

3. Tecnologias Utilizadas

- YOLO (You Only Look Once): modelo de detecção em tempo real
- PyTorch: framework para treinamento e inferência do modelo
- Label Studio: ferramenta para anotação de dados
- Python + OpenCV: captura e processamento de imagens
- SQLite / API REST (Node.js): persistência de dados

4. Pipeline de Visão Computacional

4.1 Captura de Imagem/Vídeo

A captura foi realizada em ambiente controlado, utilizando câmera posicionada acima da superfície onde os produtos são exibidos.

- Cenário: fundo fixo (mesa)
- Iluminação controlada
- Produtos posicionados individualmente
- Duas câmeras nas diagonais, para detecção

4.2 Detecção de Objetos (ROI)

Foi utilizado o modelo YOLO para detectar automaticamente os produtos na imagem.

Exemplo de saída do modelo:

- Feijão: 85%
- Espaguete: 80%
- Arroz: 90%

Cada detecção gera:

- Bounding Box (ROI)
- Classe predita
- Confiança da predição

4.3 Classificação

As classes definidas inicialmente foram:

- Arroz
- Feijão
- Espaguete
- Fubá

- Açúcar
- Óleo

A classificação é feita diretamente pelo modelo YOLO, que combina detecção + classificação.

Definimos esses alimentos, a partir de contagens anteriores do projeto liderança empática, esses são os alimentos que mais tiveram doações.

4.4 Contagem de Itens (Evitar Duplicidade)

Foi implementada uma estratégia inicial de contagem baseada em:

- Controle por frame
- Identificação de posição (bounding box)
- Verificação de proximidade entre detecções consecutivas

Regras utilizadas:

- Um item só é contado uma vez se permanecer na mesma posição
- Novo item só é contado se houver deslocamento significativo ou nova detecção fora da área anterior

Essa abordagem é simplificada, mas funcional para PoC.

5. Dataset

5.1 Coleta de Dados

Os dados foram coletados manualmente, utilizando imagens reais dos produtos:

- Arroz
- Feijão
- Macarrão
- Fubá
- Açúcar
- Óleo

Total inicial: dataset pequeno (PoC), com imagens em diferentes ângulos e posições.

5.2 Rotulagem

A anotação foi feita utilizando o Label Studio, com:

- Bounding boxes
- Classes associadas (Arroz, Feijão, Macarrão)

Processo:

1. Upload das imagens
2. Marcação manual dos objetos
3. Exportação no formato YOLO

6. Treinamento do Modelo

O modelo YOLO foi treinado utilizando PyTorch com:

- Dataset anotado
- Divisão treino/validação
- Ajuste de hiperparâmetros básicos

6.1 Métricas Utilizadas

- Precisão (Precision)
- Recall
- mAP (mean Average Precision)

7. Avaliação do Modelo

7.1 Resultados Preliminares

- Boa detecção em ambiente controlado
- Alta confiança (>80%) nos itens principais
- Pequena confusão entre itens específicos

7.3 Análise de Erros

Principais problemas identificados:

- Embalagens semelhantes confundem o modelo
- Baixa variação de dataset
- Sensibilidade à iluminação

Melhorias propostas:

- Aumentar dataset
- Data augmentation
- Ajuste de classes (ex: separar macarrão)

8. Integração com Backend

Foi implementada uma estrutura mínima para registro dos eventos.

Dados registrados:

- Tipo do item (classe)
- Confiança da predição
- Timestamp
- Identificação da equipe (simulado)

Exemplo de registro:

```
{  
  "item": "Arroz",  
  "confianca": 0.90,  
  "timestamp": "2026-04-27T19:30:00",  
  "equipe": "Equipe A"  
}
```

Persistência realizada em:

- SQLite (local) ou
- API REST (Node.js)

9. Resultados da PoC

A PoC demonstrou que:

- O modelo detecta corretamente os produtos
- A classificação é funcional com boa confiança
- A contagem básica evita duplicidade
- O sistema registra eventos corretamente
- O pipeline completo funciona de ponta a ponta

10. Limitações

- Dataset reduzido
- Ambiente controlado (não robusto ainda)

- Contagem simplificada
- Sem deploy completo

11. Próximos Passos

Para evolução da solução:

- Expandir dataset (mais produtos e cenários)
- Melhorar modelo (fine-tuning)
- Implementar tracking (ex: Deep SORT)

12. Conclusão

A Prova de Conceito valida que a abordagem técnica utilizando YOLO, PyTorch e Label Studio é viável para identificação e contagem automatizada de alimentos.

O sistema já executa o pipeline completo de visão computacional, demonstrando que está pronto para evolução para uma versão final integrada com aplicação mobile, backend robusto e deploy em produção.